LAPORAN PROJECT PEMBELAJARAN MESIN DASAR

SEMESTER GENAP 2025/2026

IDENTITAS PROYEK	
Judul	Perbandingan Algoritma KNN dan Random Forest untuk Prediksi Tingkat Kecanduan Smartphone
Topik	Klasifikasi
Identitas Penyusun	1. Eka Aliya (24031554012) 2. Salsabila Alika Seftizianka (24031554117) 3. Atya Azharina Aziz (24031554194)
Kelas	2024 A

1. PENDAHULUAN

1.1. Latar Belakang (min. 250 kata)

Pada era transformasi digital saat ini, *smartphone* telah menjadi instrumen esensial yang memfasilitasi komunikasi, edukasi, dan hiburan bagi hampir seluruh lapisan masyarakat [1]. Namun, kemudahan akses yang ditawarkan juga membawa risiko peningkatan ketergantungan yang signifikan. Fenomena kecanduan *smartphone* kini diakui sebagai isu kritis yang seringkali berkorelasi dengan penurunan performa akademik, stres psikologis, hingga gangguan pola tidur [2]. Data menunjukkan bahwa pola perilaku digital seperti durasi penggunaan layar (*screen time*) yang berlebihan dan interaksi media sosial yang kompulsif merupakan indikator kuat dari risiko kecanduan tersebut [3].

Secara tradisional, penilaian tingkat kecanduan dilakukan melalui kuesioner mandiri yang bersifat subjektif dan rentan terhadap bias informasi [2]. Oleh karena itu, diperlukan pendekatan yang lebih objektif melalui pemanfaatan teknik *machine learning* untuk menganalisis metrik perilaku digital secara terukur [4]. Dengan memproses variabel data seperti waktu penggunaan harian, frekuensi pengecekan notifikasi, dan jenis aplikasi yang diakses, model prediktif dapat memberikan klasifikasi tingkat risiko yang lebih akurat [5].

1. PENDAHULUAN

Dalam domain klasifikasi data, algoritma K-Nearest Neighbors (KNN) dikenal efektif karena kemampuannya memetakan pola berdasarkan kemiripan perilaku antar pengguna dalam ruang multidimensi [4]. Di sisi lain, Random Forest seringkali memberikan keunggulan dalam menangani dataset yang kompleks dan bervariasi dengan tingkat akurasi yang tinggi melalui mekanisme *ensemble learning* [5]. Penelitian ini bertujuan untuk membandingkan efektivitas kedua algoritma tersebut dalam memprediksi tingkat kecanduan *smartphone*, guna memberikan solusi data yang reliabel dalam mendukung upaya deteksi dini dan intervensi kesehatan mental di lingkungan mahasiswa.

1.2. Rumusan Masalah dan Tujuan

Rumusan Masalah pada penelitian ini sebagai berikut:

1. Bagaimana cara mengimplementasikan algoritma K-Nearest Neighbors (KNN) dan Random Forest dalam mengklasifikasikan tingkat kecanduan smartphone terhadap individu?
2. Bagaimana perbandingan performa (akurasi, presisi, recall, dan F1-Score) antara algoritma KNN dan Random Forest untuk memprediksi tingkat kecanduan tersebut?
3. Variabel atau fitur apa saja yang memiliki pengaruh paling signifikan terhadap tingkat kecanduan smartphone berdasarkan model yang dikembangkan?

Oleh karena itu, tujuan dari penelitian ini adalah:

1. Menerapkan algoritma KNN dan Random Forest untuk membangun model prediksi tingkat kecanduan smartphone yang objektif.
2. Menganalisis dan membandingkan tingkat akurasi antara algoritma KNN dan Random Forest guna menemukan model terbaik untuk dataset yang digunakan.
3. Memberikan wawasan mengenai faktor-faktor utama yang memicu kecanduan smartphone guna mendukung upaya pencegahan atau penanganan masalah tersebut di lingkungan kampus.

2. METODOLOGI

2.1. Eksplorasi Dataset

Dataset yang digunakan dalam penelitian ini adalah **Smartphone Usage and Addiction Analysis Dataset** yang bersumber dari *Kaggle*. Dataset ini berisi tentang informasi pola penggunaan *smartphone* dan indikator kecanduan pada 7.500 individu dengan total 16 kolom.
Variabel-variabel yang terdapat pada dataset ini meliputi waktu penggunaan layar harian, jumlah pembukaan aplikasi, waktu yang dihabiskan di media sosial, durasi tidur, tingkat produktivitas, frekuensi pengecekan ponsel, dan lain-lain. Selain itu, juga terdapat atribut demografis seperti usia, jenis kelamin, dan pekerjaan. Label yang digunakan pada penelitian ini berdasarkan pada kolom *addiction level* yang mengkategorikan setiap individu pada tingkatan tertentu, seperti *None, Mild, Moderate*, dan *Severe*.

2.2. Tahapan Penelitian

Penelitian ini dilakukan melalui beberapa tahapan teknis sebagai berikut:

1. Input dataset *Smartphone Usage* dari sumber kaggle
2. Cek informasi dataset
3. Selanjutnya, Dropping kolom terkait *ID* dan kolom yang tidak relevan
4. Dilakukan penanganan missing value dan data duplikasi
5. Pengecekan *outlier* menggunakan visualisasi *boxplot*
6. *Encoding* kolom kategorikal seperti kolom *stress level, gender, academic work impact*
7. Kolom *addiction level* dilakukan *ordinal encoding*
8. Dilakukan standarisasi data pada fitur-fitur numerik
9. Menetapkan *addiction level* sebagai label data
10. Cek Distribusi label, jika terjadi Imbalanced Label, lakukan SMOTE
    Synthetic Minority Over Sampling Technique atau SMOTE merupakan Teknik penyeimbangan dataset dengan cara menambah jumlah sampel pada kelas minoritas secara sintetis. Berbeda dengan *oversampling* biasa yang menduplikasi data, SMOTE menciptakan data baru di antara titik-titik data minoritas yang sudah ada
11. Membuat *heatmap* korelasi dan *Bar Chart* untuk melihat korelasi antar variabel
12. Feature selection berdasarkan korelasi antar variabel
13. Penentuan Label
14. Split data menjadi 80% *train* dan 20% *test*
15. Membangun model *KNN* dan *Random Forest*
    K-Nearest Neighbors atau KNN merupakan salah satu algoritma supervised yang bekerja dengan cara mencari pola kemiripan antara data baru dengan data yang sudah ada (tetangga terdekat). Klasifikasi ditentukan berdasarkan voting mayoritas label dari sejumlah k tetangga terdekat menggunakan metrik perhitungan jarak, seperti jarak euclidean. Sementara Random Forest merupakan salah satu algoritma supervised yang berbasis *ensemble learning* yang terdiri dari banyak pohon keputusan. Algoritma ini bekerja dengan membangun beberapa pohon secara acak (*bagging*) dan menggabungkan hasil prediksinya melalui voting mayoritas untuk

2. METODOLOGI

meningkatkan akurasi dan mencegah *overfitting*.

16. Melakukan evaluasi model melalui *confusion matrix* dan *classification report* yang berisikan *akurasi, presisi, recall*, dan *F1-Score*

    Accuracy digunakan untuk mengukur seberapa tepat model memprediksi data secara keseluruhan, dengan rumus:

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN}$$

Precision digunakan mengukur ketepatan antara data yang diminta dengan hasil prediksi yang diberikan oleh model, dengan rumus:

$$\text{Precision} = \frac{TP}{TP+FP}$$

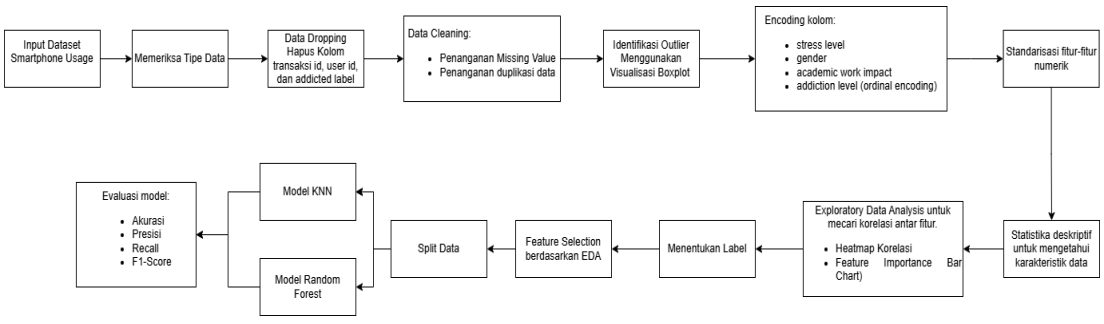
Recall digunakan mengukur sensitivitas atau keberhasilan model dalam memprediksi kembali sebuah kelas, dengan rumus:

$$Recall = \frac{TP}{TP + FN}$$

F1-score digunakan sebagai Rata-rata harmonik antara presisi dan recall, digunakan jika sebaran data tidak seimbang, dengan rumus:

$$\text{F1-Score} = 2 \times \frac{\text{Presisi} \times \text{Recall}}{\text{Presisi} + \text{Recall}}$$

Berikut Diagram Alur Penelitian ini:



2. METODOLOGI

Diagram Model KNN:

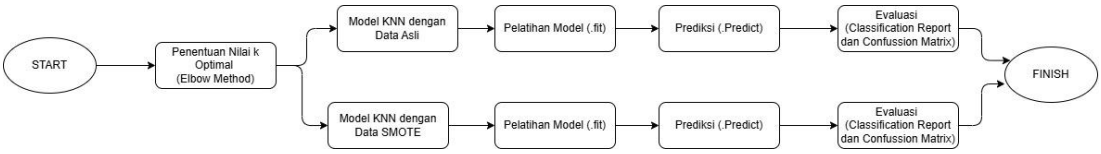
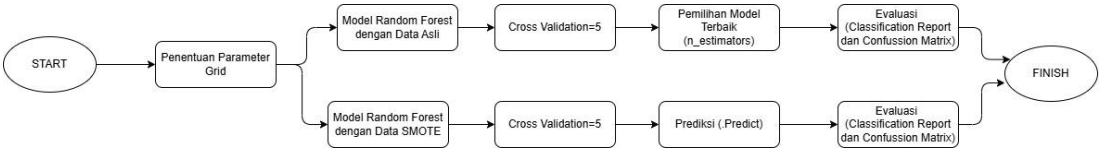


Diagram Model Random Forest:



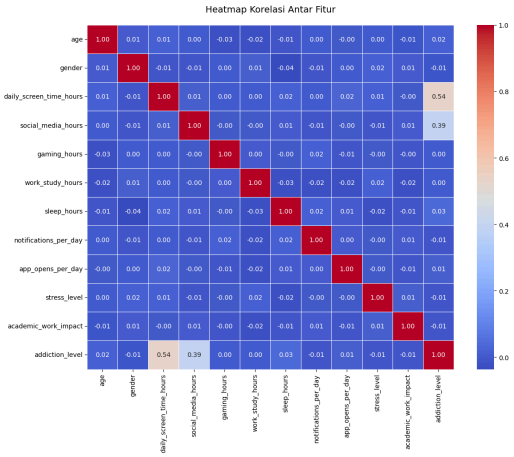
Rencana Output:

1. Model Klasifikasi: Dua model *machine learning* (*KNN* dan *Random Forest*) yang telah dioptimasi untuk prediksi tingkat kecanduan *smartphone.*
2. Analisis Komparatif: Laporan komprehensif mengenai perbandingan efisiensi dan akurasi kedua algoritma dalam menangani data perilaku digital.
3. Identifikasi Faktor Kunci: Visualisasi fitur-fitur yang menjadi kontributor utama (pemicu) kecanduan *smartphone* sebagai dasar referensi untuk upaya edukasi kesehatan mental digital di lingkungan kampus.

3. HASIL DAN ANALISIS

3.1 Eksploratory Data Analysis

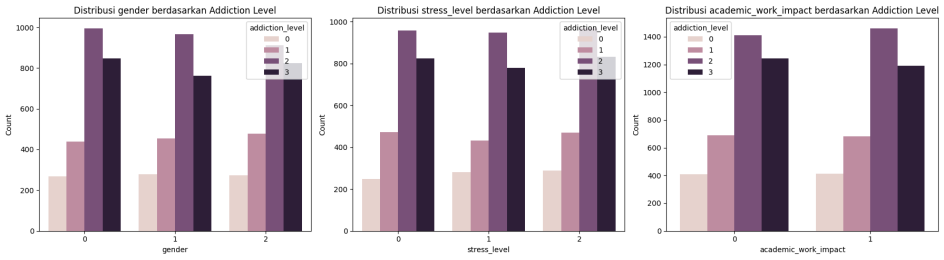
1. Heatmap Korelasi Antar Fitur



Berdasarkan Visualisasi Heatmap Korelasi diatas, fitur *daily_screen_time_hours* menunjukkan nilai korelasi positif tertinggi terhadap variabel *addiction_level* sebesar 0.54, diikuti oleh fitur *social_media_hours* dengan nilai korelasi sebesar 0.39. Nilai tersebut menunjukkan bahwa terdapat hubungan yang searah, artinya setiap peningkatan durasi layar harian dan waktu akses media sosial berkontribusi langsung secara linier terhadap tingginya tingkat kecanduan smartphone pada pengguna. Sebaliknya, fitur-fitur seperti age, gaming_hours, work_studi_hours, dan lain-lain menunjukkan nilai koefisien yang sangat mendekati 0.00. Nilai yang mendekati nol ini menandakan bahwa fitur-fitur tersebut tidak memiliki hubungan linier yang berarti terhadap target *addiction_level*, sehingga polanya cenderung acak atau kemungkinan memiliki hubungan non-linier.

2. Distribusi Fitur Kategorik Pada Addiction Level

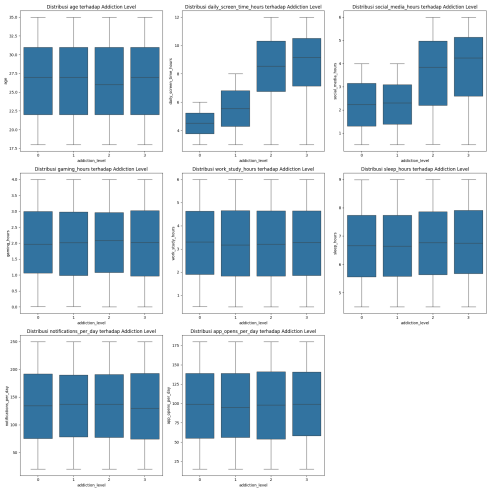
Analisis distribusi fitur-fitur kategorikal, yang meliputi variabel *Gender*, *Stress Level*, dan *Academic/Work Impact* terhadap tingkat kecanduan pengguna dengan menggunakan *grouped bar chart* seperti yang ditunjukkan pada visualisasi berikut.



Berdasarkan grafik distribusi tersebut, proporsi sebaran data untuk setiap kategori di dalam fitur *Gender*, *Stress Level*, dan *Academic/Work Impact* terpantau memiliki pola frekuensi yang serupa di setiap tingkatan *addiction_level*. Di setiap kelompok fitur kategorikal tersebut, kelas *Moderate* (label 2) dan *Severe* (label 3) secara konsisten mendominasi pengisian frekuensi data di seluruh sub-kategori, sementara kelas *None* (label 0) selalu menjadi kelompok minoritas dengan frekuensi terendah. Fenomena visual ini mengindikasikan bahwa faktor-faktor kategorikal tersebut tersebar merata di dalam dataset dan karakteristik distribusinya tidak menunjukkan pola diskriminasi yang ekstrem antar-kategori, melainkan sangat dipengaruhi oleh adanya ketimpangan jumlah sampel awal (*class imbalance*) dari variabel target itu sendiri.

3. Distribusi Fitur Numerik Pada Addiction Level

Untuk memahami karakteristik perilaku pengguna pada setiap tingkat kecanduan, dilakukan analisis menggunakan grafik *boxplot* untuk setiap fitur numerik terhadap variabel *addiction_level* seperti yang disajikan pada visualisasi boxplot berikut ini.

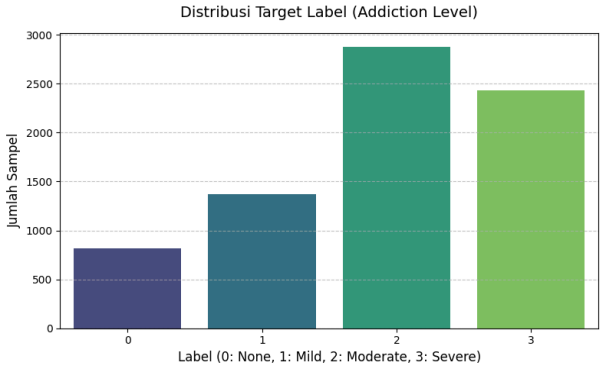


Berdasarkan visualisasi tersebut, fitur *Daily Screen Time Hours* dan *Social Media Hours* menunjukkan tren peningkatan yang linier dan kontras seiring dengan meningkatnya level kecanduan, di mana pengguna pada tingkat *Moderate* (2) dan *Severe* (3) secara jelas memiliki nilai median serta rentang kuartil waktu layar dan penggunaan media sosial yang jauh lebih tinggi dibandingkan dengan kelas *None* (0) dan *Mild* (1). Sebaliknya, untuk fitur-fitur lain seperti *Age*, *Gaming Hours*, *Work/Study Hours*, *Sleep Hours*, *Notifications per Day*, dan *App Opens per Day*, distribusi nilai median serta rentang interkuartil (IQR) milik mereka cenderung seragam dan saling tumpang tindih (*overlapping*) di seluruh tingkatan *addiction_level*. Hal ini mengindikasikan bahwa secara independen, fitur-fitur tersebut memiliki batas pemisah yang lemah dalam membedakan tingkat kecanduan pengguna,

sehingga algoritma berbasis jarak murni seperti K-Nearest Neighbors (KNN) berpotensi besar mengalami kesulitan dalam melakukan klasifikasi jika tidak dikombinasikan dengan teknik optimasi parameter atau penyeimbangan data yang tepat.

4. Distribusi Target Label

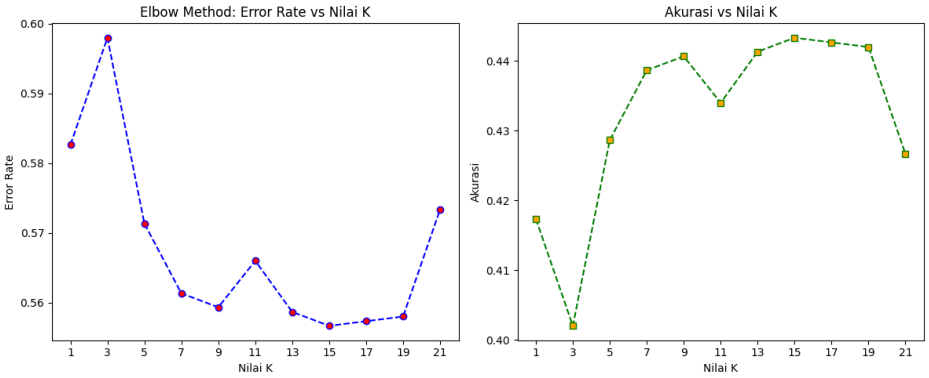
   Selanjutnya, dilakukan evaluasi menyeluruh terhadap sebaran jumlah sampel pada variabel target *addiction_level* melalui grafik *bar chart* yang disajikan pada visualisasi berikut.



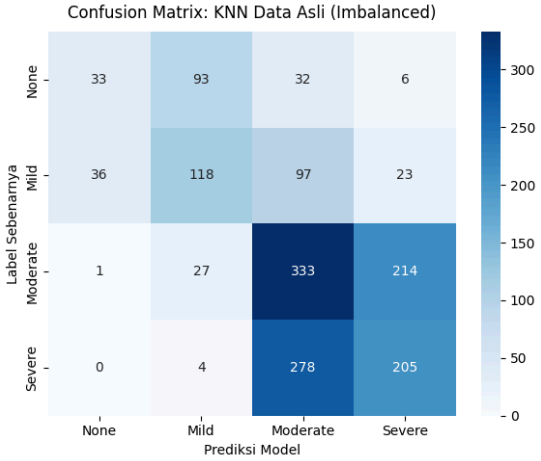
   Berdasarkan grafik tersebut, ditemukan kondisi ketimpangan kelas (*class imbalance*) yang sangat jelas, di mana kelompok pengguna tingkat *Moderate* (label 2) dan *Severe* (label 3) menguasai sebagian besar dataset dengan jumlah sampel. Di sisi lain, kelompok pengguna dengan tingkat kecanduan *Mild* (label 1) berada di posisi tengah dengan intensitas sekitar 1400 sampel, sementara tingkat *None* (label 0) secara kontras bertindak sebagai kelas minoritas ekstrem karena memiliki kuantitas sampel paling sedikit di bawah kisaran 1000 data. Hal ini menunjukkan jika pembuatan model klasifikasi nantinya hanya mengandalkan data asli (*imbalanced*) akan sangat berisiko menghasilkan model yang bias ke kelas mayoritas. Oleh karena itu, analisis distribusi ini menjadi jembatan dan landasan akademis yang kuat untuk menerapkan metode Synthetic Minority Over-sampling Technique (SMOTE) serta standarisasi fitur pada tahapan eksperimen, guna memastikan model KNN dan *Random Forest* yang dibangun nanti dapat mengidentifikasi setiap tingkatan kecanduan secara adil dan objektif.

3.2 Implementasi Algoritma KNN dan Random Forest

Pada tahap implementasi model KNN dan Random Forest, masing-masing model dibuat dengan dua eksperimen yang berbeda, yaitu dengan data asli (imbalanced data) dan data SMOTE. Tahap awal dalam membuat model KNN yaitu menentukan jumlah k optimal dengan menggunakan metode Elbow, hal ini bertujuan untuk menghindari risiko hasil voting seri maupun masalah overfitting.

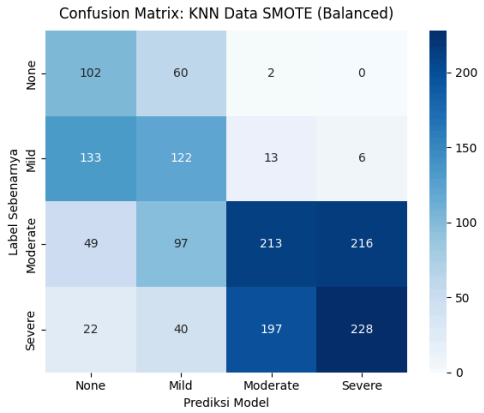


Berdasarkan grafik Elbow diatas, titik siku pada grafik terdapat pada angka 15, hal ini menunjukkan bahwa nilai k optimal untuk model KNN pada dataset ini adalah 15. Selanjutnya, dengan data train 80% dan data test 20%, serta proses standarisasi, dilakukan eksperimen pertama pada model dengan menggunakan data asli (imbalanced data), diperoleh akurasi sebesar 46%, lalu untuk eksperimen kedua dengan data SMOTE, diperoleh hasil akurasi sebesar 44%. Berdasarkan akurasi, model KNN dengan data asli lebih unggul daripada model dengan data SMOTE, namun jika dianalisis secara mendalam pada classification report, terdapat sebuah kelemahan pada model tersebut, yang mana nilai recall untuk label None (0) sangat rendah, yaitu hanya sebesar 20%, hal ini menunjukkan jika model hanya berhasil menebak benar sebanyak 33 data dari total 164 data test pada label tersebut. Dengan persentase gagal menebak sebesar 80% pada label None, menunjukkan jika model pada eksperimen pertama mengalami ke biasan dan cenderung melempar hasil prediksi pada label tersebut ke arah kelas Mild, seperti yang ditunjukkan pada confusion matrix berikut.



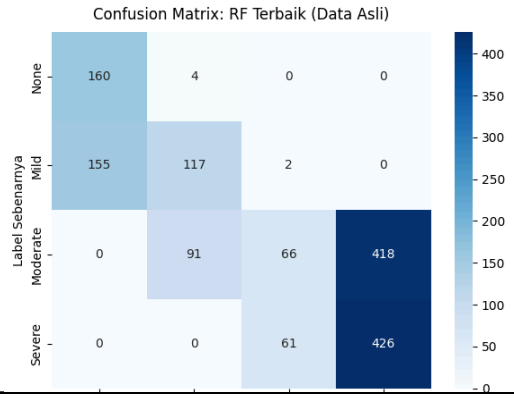
Sementara itu, pada eksperimen kedua, dengan akurasi sebesar 44%, terdapat peningkatan signifikan pada nilai recall label None (0), yaitu sebesar 62%, hal ini menunjukkan bahwa model berhasil

menebak 102 data dari total 164 data, lebih tinggi daripada model eksperimen pertama.

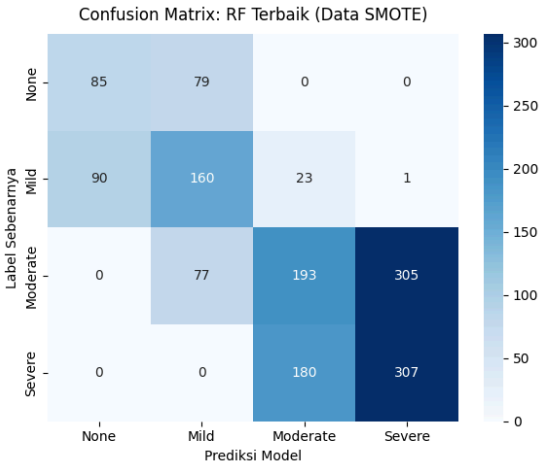


Dengan demikian, melakukan SMOTE pada data yang imbalanced dapat terbukti berhasil mempertegas batas keputusan model KNN, sehingga dapat jauh lebih sensitif dan adil dalam mengenali karakteristik pengguna di setiap tingkatan kelas.

Selanjutnya, pada tahap implementasi model Random Forest dengan metode GridSearchCV, diawali dengan menentukan parameter grid, seperti n_estimators, max_depth, min_samples_split, dan class_weight, lalu dilakukan penentuan nilai Cross Validation yaitu 5 Fold, artinya dataset dibagi menjadi 5 bagian yang sama besar, serta model dilatih sebanyak 5 kali, dengan 4 bagian untuk melatih dan 1 bagian untuk menguji performa secara bergantian. Pada eksperimen pertama dengan data asli (imbalanced data), dengan hasil kombinasi parameter yang optimal untuk model tersebut, yaitu class_weight='balanced_subsample', max_depth=7, min_samples_spilt=5, dan n_estimators=300, diperoleh hasil akurasi sebesar 51.27%. Berdasarkan nilai akurasi tersebut, eksperimen pertama ini sekilas memberikan performa yang cukup baik. Jika dianalisis lebih dalam pada tebakan kelasnya, penggunaan parameter *class_weight* terbukti sangat sukses menyelamatkan kelas minoritas, di mana nilai *recall* untuk label *None* (0) mencapai 98% (berhasil menebak benar sebanyak 160 sampel dari total 164 data uji). Namun, jika dilihat dalam *confusion matrix* berikut ini, karena model terlalu fokus menghindari penalti pada kelas *None*, model menjadi bias di kelas lain dan mengorbankan label *Moderate* (2) yang nilai *recall* nya hanya sebesar 11% saja.



Sementara itu, pada eksperimen kedua dengan menggunakan data SMOTE, diperoleh hasil kombinasi parameter terbaik yaitu *class_weight*='balanced', *max_depth*='None', *min_samples_split*=2, dan *n_estimators*=200, dengan perolehan hasil akurasi sebesar 49.67%. Meskipun secara keseluruhan akurasinya mengalami penurunan jika dibandingkan dengan menggunakan data asli, model Random Forest pada eksperimen kedua ini menunjukkan performa tebakan yang jauh lebih sehat, stabil, dan matang. Nilai *recall* untuk label *None* berada di angka 52% (berhasil menebak 85 data dari 164 data aktual), namun model tidak mengorbankan kelas lainnya secara ekstrem seperti pada eksperimen pertama. Dengan demikian, eksperimen kedua ini terbukti menghasilkan model *Random Forest* yang paling objektif dan sehat. Visualisasi *confusion matrix* pada eksperimen kedua ini menunjukkan bahwa pohon-pohon keputusan mampu menyebarkan kemampuan prediksinya secara adil dan merata di setiap tingkatan kelas kecanduan, sehingga model ini jauh lebih andal untuk digunakan pada data baru di dunia nyata.



3.3 Perbandingan Performa Model KNN dan Random Forest

Perbandingan performa KNN dan Random Forest pada penelitian ini dilakukan menggunakan confusion matrix dan matriks akurasi, presisi, recall, serta F1-Score. Tahapan perbandingan ini dilakukan untuk mengetahui pendekatan metode mana yang paling cocok dengan dataset *Smartphone Usage and Addiction Analysis.*

A. Hasil Evaluasi Model KNN Data Asli Tanpa Dilakukan SMOTE

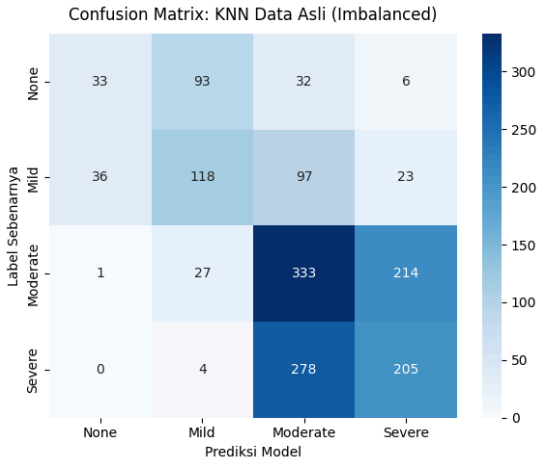
```
Akurasi Keseluruhan: 45.93%

Classification Report:
              precision    recall  f1-score   support

        None       0.47      0.20      0.28       164
        Mild       0.49      0.43      0.46       274
    Moderate       0.45      0.58      0.51       575
      Severe       0.46      0.42      0.44       487

    accuracy                           0.46      1500
   macro avg       0.47      0.41      0.42      1500
weighted avg       0.46      0.46      0.45      1500
```

Pada pengujian pertama, metode KNN diterapkan pada dataset asli yang tanpa dilakukan handling imbalance data (SMOTE). Berdasarkan hasil pengujian, model KNN tanpa SMOTE memperoleh nilai akurasi sebesar 45.93%. Nilai tersebut menunjukkan bahwa model mampu memprediksi data dengan benar sebanyak 45,93% dari total data uji. Pada kelas *None*, model memperoleh precision sebesar 47%, recall sebesar 20%, dan F1-score sebesar 28%. Hasil ini menunjukkan bahwa model masih mengalami kesulitan dalam mengenali data pada kelas *None*. Sedangkan kelas *Mild*, model memperoleh precision sebesar 49%, recall sebesar 43%, dan F1-score sebesar 46%. Hasil tersebut menunjukan model lebih baik dalam mengenali kelas Mild dibandingkan dengan kelas None. Sementara itu, pada kelas *Moderate*, model menunjukkan performa terbaik dengan precision sebesar 45%, recall sebesar 58%, dan F1-score sebesar 51%. Sedangkan pada kelas *Severe*, diperoleh precision sebesar 46%, recall sebesar 42%, dan F1-score sebesar 44%.



Confusion matrix menunjukan seberapa banyak data uji yang diprediksi benar dan salah pada kelas yang lainnya. Berdasarkan confusion matrix yang dihasilkan, model masih cukup banyak melakukan kesalahan klasifikasi. Pada kelas *None*, hanya 33 data yang berhasil diprediksi dengan benar, sedangkan sebagian besar data salah diklasifikasikan ke kelas *Mild* sebanyak 93 data. Pada kelas *Mild*, model berhasil memprediksi benar sebanyak 118 data, namun masih terdapat kesalahan prediksi ke kelas *Moderate* sebanyak 97 data. Hal ini

menunjukkan bahwa model mengalami kesulitan dalam membedakan karakteristik antara kelas *Mild* dan *Moderate*. Untuk kelas *Moderate*, model mampu memprediksi dengan benar sebanyak 333 data. Namun, masih terdapat cukup banyak data yang salah diprediksi menjadi kelas *Severe* sebanyak 214 data. Sedangkan, pada kelas *Severe*, model hanya berhasil memprediksi benar sebanyak 205 data, sedangkan sebanyak 278 data salah diklasifikasikan ke kelas *Moderate*. Banyaknya kesalahan klasifikasi antara kelas Moderate dan Serve menunjukan bahwa kedua kelas tersebut memiliki pola data yang cukup mirip, sehingga model KNN mengalami kesulitan dalam membedakan kedua kelas tersebut.

B. Hasil Evaluasi Model KNN Dilakukan SMOTE

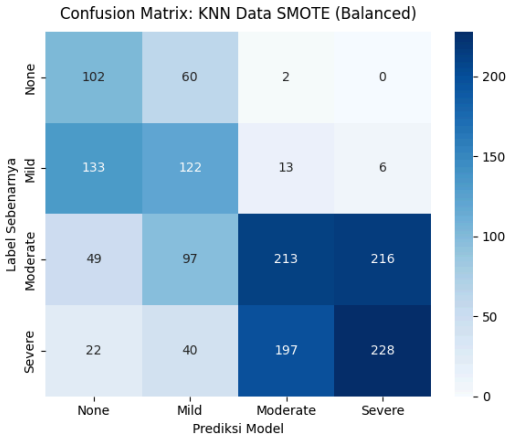
```
Akurasi Keseluruhan: 44.33%

Classification Report:
              precision    recall  f1-score   support

        None       0.33      0.62      0.43       164
        Mild       0.38      0.45      0.41       274
    Moderate       0.50      0.37      0.43       575
      Severe       0.51      0.47      0.49       487

    accuracy                           0.44      1500
   macro avg       0.43      0.48      0.44      1500
weighted avg       0.46      0.44      0.44      1500
```

Pada pengujian kedua, penerapan model KNN dilakukan pada data yang telah dilakukan imbalance data menggunakan SMOTE. Berdasarkan hasil pengujian, model KNN dengan SMOTE memperoleh nilai akurasi sebesar 44.33%. Nilai tersebut menunjukkan bahwa model mampu memprediksi data dengan benar sebanyak 44,33% dari total data uji. Pada kelas *None*, model memperoleh precision sebesar 33%, recall sebesar 62%, dan F1-score sebesar 43%. Hasil tersebut menunjukkan bahwa penerapan SMOTE membantu model dalam mengenali kelas *None* dengan lebih baik, terutama pada nilai recall yang mengalami peningkatan signifikan dibandingkan sebelum dilakukan penerapan SMOTE. Sedangkan pada kelas *Mild*, model memperoleh precision sebesar 38%, recall sebesar 45%, dan F1-score sebesar 41%. Hasil tersebut menunjukkan bahwa model cukup mampu mengenali kelas *Mild*, meskipun masih terdapat beberapa kesalahan klasifikasi pada kelas tersebut. Nilai Recall pada kelas ini lebih baik dibandingkan dengan recall sebelum dilakukan SMOTE. Sementara itu, pada kelas *Moderate*, model memperoleh precision sebesar 50%, recall sebesar 37%, dan F1-score sebesar 43%. Sedangkan pada kelas *Severe*, diperoleh precision sebesar 51%, recall sebesar 47%, dan F1-score sebesar 49%. Hasil tersebut menunjukkan bahwa model memiliki kemampuan yang cukup baik dalam mengenali kelas *Severe*, meskipun masih terjadi kesalahan prediksi antara kelas *Moderate* dan *Severe*. Penerapan metode SMOTE mampu meningkatkan prediksi data pada setiap kelas. Namun, belum mampu meningkatkan nilai akurasi model.



Berdasarkan confusion matrix yang dihasilkan, terlihat bahwa model KNN dengan SMOTE mampu meningkatkan jumlah prediksi benar pada beberapa kelas dibandingkan sebelum dilakukan SMOTE. Pada kelas None, model berhasil memprediksi benar sebanyak 102 data dari total 164 data. Hal ini menunjukkan bahwa penggunaan SMOTE membantu model dalam mengenali kelas minoritas dengan lebih baik. Hasil ini jauh signifikan dibandingkan tidak dilakukan SMOTE. Pada kelas Mild, model berhasil memprediksi benar sebanyak 122 data, namun masih terdapat kesalahan klasifikasi ke kelas None sebanyak 133 data. Hal ini menunjukkan bahwa model masih mengalami kesulitan dalam membedakan karakteristik antara kedua kelas tersebut. Untuk kelas Moderate, model berhasil memprediksi benar sebanyak 213 data, tetapi masih banyak data yang salah diprediksi menjadi kelas Severe sebanyak 216 data. Sementara itu, pada kelas Severe, model mampu memprediksi benar sebanyak 228 data, namun terdapat 197 data yang salah diklasifikasikan menjadi kelas Moderate.Banyaknya kesalahan klasifikasi antara kelas Moderate dan Severe menunjukkan bahwa kedua kelas tersebut memiliki pola data yang mirip sehingga algoritma KNN masih kesulitan dalam membedakan kedua kelas tersebut. Walaupun akurasi model sedikit menurun dibandingkan KNN tanpa SMOTE, penggunaan SMOTE membantu model menjadi lebih seimbang dalam mengenali seluruh kelas, khususnya pada kelas minoritas.

C. Hasil Evaluasi Model Random Forest Data Asli Tanpa Dilakukan SMOTE

```
Akurasi Akhir Random Forest (Data Asli): 51.27%

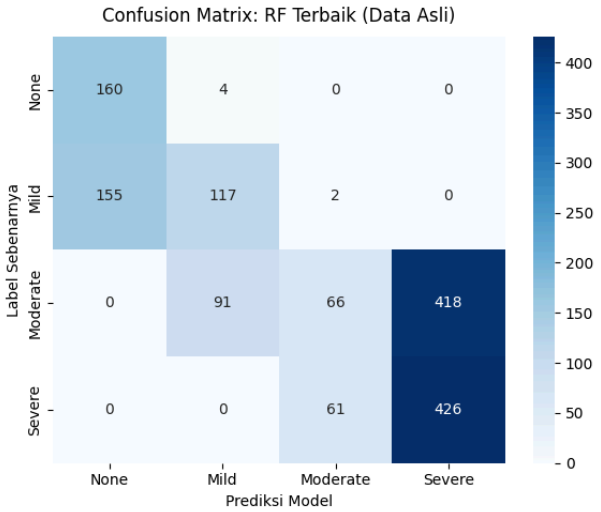
Classification Report:
              precision    recall  f1-score   support

        None       0.51      0.98      0.67       164
        Mild       0.55      0.43      0.48       274
    Moderate       0.51      0.11      0.19       575
      Severe       0.50      0.87      0.64       487

    accuracy                           0.51      1500
   macro avg       0.52      0.60      0.49      1500
weighted avg       0.52      0.51      0.44      1500
```

Pada pengujian ketiga, metode Random Forest diterapkan pada dataset asli tanpa dilakukan

handling imbalance data menggunakan SMOTE. Berdasarkan hasil pengujian, model Random Forest tanpa SMOTE memperoleh nilai akurasi sebesar 51.27%. Nilai tersebut menunjukkan bahwa model mampu memprediksi data dengan benar sebanyak 51,27% dari total data uji. Hasil ini menunjukan model Random Forest lebih baik dibandingkan dengan metode KNN. Pada kelas None, model memperoleh precision sebesar 51%, recall sebesar 98%, dan F1-score sebesar 67%. Hasil tersebut menunjukkan bahwa model sangat baik dalam mengenali kelas None karena hampir seluruh data pada kelas tersebut berhasil diprediksi dengan benar. Sedangkan pada kelas Mild, model memperoleh precision sebesar 55%, recall sebesar 43%, dan F1-score sebesar 48%. Hasil tersebut menunjukkan bahwa model cukup mampu mengenali kelas Mild, meskipun masih terdapat beberapa kesalahan klasifikasi. Sementara, pada kelas Moderate, model memperoleh precision sebesar 51%, recall sebesar 11%, dan F1-score sebesar 19%. Nilai recall yang sangat rendah menunjukkan bahwa model mengalami kesulitan dalam mengenali data pada kelas Moderate. Sebagian besar data pada kelas tersebut salah diprediksi ke kelas lain. Pada kelas Severe, model memperoleh precision sebesar 50%, recall sebesar 87%, dan F1-score sebesar 64%. Hasil tersebut menunjukkan bahwa model memiliki kemampuan yang sangat baik dalam mengenali kelas Severe. Secara keseluruhan, model Random Forest tanpa SMOTE menghasilkan nilai akurasi yang lebih tinggi dibandingkan model KNN. Namun, model masih mengalami ketidakseimbangan performa pada beberapa kelas, terutama pada kelas Moderate yang memiliki nilai recall sangat rendah.



Berdasarkan hasil confusion matrix yang dihasilkan, Random Forest dapat melakukan prediksi sangat baik pada kelas None dan Serve. Pada kelas *None*, model berhasil memprediksi benar sebanyak 160 data dari total 164 data. Sementara pada kelas *Severe*, model berhasil memprediksi benar sebanyak 426 data dari total 487 data. Pada kelas *Mild*, model berhasil memprediksi benar sebanyak 117 data, namun masih terdapat 155 data yang salah diklasifikasikan ke kelas *None*. Hal ini menunjukkan bahwa model masih mengalami kesulitan dalam membedakan karakteristik antara kelas *Mild* dan *None*. Sedangkan pada kelas

Moderate, model hanya berhasil memprediksi benar sebanyak 66 data dari total 575 data. Sebanyak 418 data salah diprediksi menjadi kelas *Serve*. Hal ini menunjukkan bahwa model juga mengalami kesulitan dalam mengenali pola kelas *Moderate* sehingga banyak data yang berpindah ke kelas dengan karakteristik yang mirip. Meskipun masih terdapat kesalahan prediksi pada kelas *Mild* dan *Moderate,* metode Random Forest tanpa dilakukan SMOTE memberikan hasil performa lebih baik dibandingkan dengan KNN.

D. Hasil Evaluasi Model Random Forest Dilakukan SMOTE

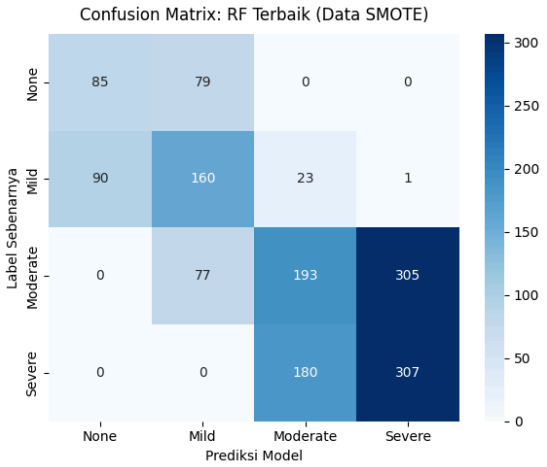
```
Akurasi Akhir Random Forest (Data SMOTE): 49.67%

Classification Report:
              precision    recall  f1-score   support

        None       0.49      0.52      0.50       164
        Mild       0.51      0.58      0.54       274
    Moderate       0.49      0.34      0.40       575
      Severe       0.50      0.63      0.56       487

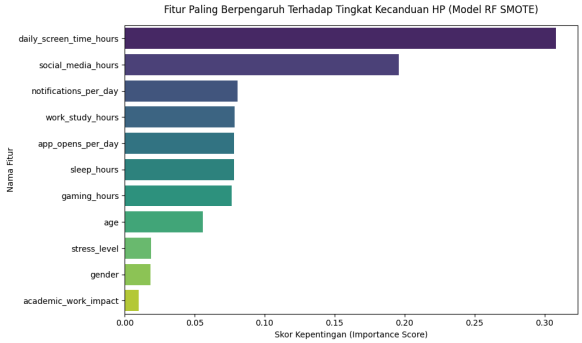
    accuracy                           0.50      1500
   macro avg       0.50      0.52      0.50      1500
weighted avg       0.50      0.50      0.49      1500
```

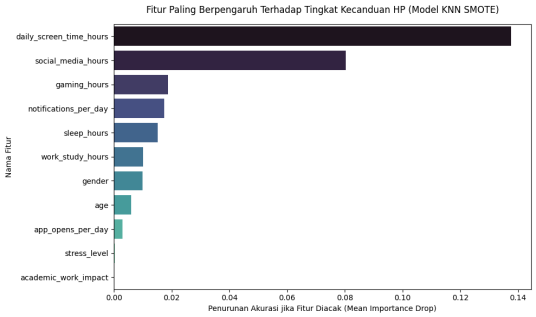
Pada pengujian keempat dilakukan penerapan metode KNN dengan data yang dilakukan penanganan imbalance data menggunakan SMOTE. Berdasarkan hasil pengujian, model Random Forest dengan SMOTE memperoleh nilai akurasi sebesar 49.67%. Nilai tersebut menunjukkan bahwa model mampu memprediksi data dengan benar sebanyak 49,67% dari total data uji. Pada kelas None, model memperoleh precision sebesar 49%, recall sebesar 52%, dan F1-score sebesar 50%. Hasil tersebut menunjukkan bahwa model cukup mampu mengenali kelas None setelah dilakukan penerapan SMOTE. Nilai recall pada kelas None yang dilakukan SMOTE jauh berbeda dengan recall tanpa dilakukan SMOTE. Sedangkan pada kelas Mild, model memperoleh precision sebesar 51%, recall sebesar 58%, dan F1-score sebesar 54%. Hasil tersebut menunjukkan bahwa model memiliki kemampuan yang cukup baik dalam mengenali kelas Mild. Sementara pada kelas Moderate, model memperoleh precision sebesar 49%, recall sebesar 34%, dan F1-score sebesar 40%. Nilai recall yang masih cukup rendah menunjukkan bahwa model masih mengalami kesulitan dalam mengenali data pada kelas Moderate. Pada kelas Severe, model memperoleh precision sebesar 50%, recall sebesar 63%, dan F1-score sebesar 56%. Hasil tersebut menunjukkan bahwa model cukup baik dalam mengenali kelas Severe dibandingkan kelas lainnya. Secara keseluruhan, penggunaan SMOTE membantu membuat performa model Random Forest menjadi lebih seimbang pada setiap kelas. Meskipun nilai akurasi sedikit menurun dibandingkan Random Forest tanpa SMOTE, namun model menghasilkan distribusi prediksi yang lebih merata dan kemampuan klasifikasi yang lebih stabil pada seluruh kelas.



Berdasarkan confusion matrix yang dihasilkan, Random Forest dengan SMOTE dapat melakukan prediksi yang lebih seimbang pada setiap kelas dibandingkan tanpa dilakukan SMOTE. Pada kelas *None*, model berhasil memprediksi benar sebanyak 85 data dari total 164 data, sedangkan sisanya masih salah diprediksi ke kelas *Mild* sebanyak 79 data. Pada kelas *Mild*, model berhasil memprediksi benar sebanyak 160 data dari total 274 data. Namun, masih terdapat beberapa kesalahan klasifikasi ke kelas *None* sebanyak 90 data dan ke kelas *Moderate* sebanyak 23 data. Sementara itu, pada kelas *Moderate*, model berhasil memprediksi benar sebanyak 193 data dari total 575 data. Namun, masih banyak data yang salah diprediksi menjadi kelas *Severe* sebanyak 305 data. Hal ini menunjukkan bahwa model masih mengalami kesulitan dalam membedakan karakteristik antara kelas *Moderate* dan *Severe*. Pada kelas *Severe*, model berhasil memprediksi benar sebanyak 307 data dari total 487 data, sedangkan sebanyak 180 data salah diprediksi menjadi kelas *Moderate*. Kesalahan klasifikasi antara kelas *Moderte* dan *Serve* tersebut menunjukkan bahwa pola data pada kelas tersebut memiliki kemiripan. Walaupun, secara akurasi *Random Forest* yang dilakukan SMOTE lebih rendah dibandingkan tanpa dilakukan SMOTE, namun dapat memberikan hasil performa klasifikasi yang lebih stabil dan merata pada setiap kelasnya.

3.4 Feature Importance Pada Setiap Model





Feature Importance Pada Setiap Model Data Smote

Analisis *feature importance* dilakukan untuk mengetahui variabel-variabel yang memberikan pengaruh paling besar terhadap prediksi tingkat kecanduan smartphone.

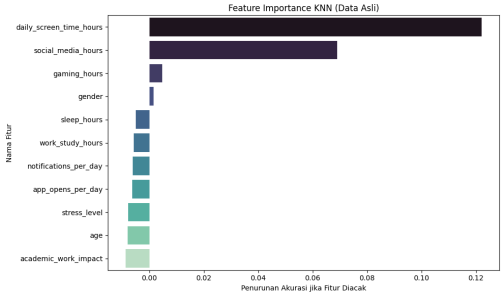
Pada model K-Nearest Neighbors (KNN), pengukuran *feature importance* dilakukan menggunakan metode *permutation importance*, yaitu dengan mengukur penurunan performa model ketika suatu fitur diacak. Metode ini digunakan karena algoritma KNN tidak memiliki atribut *feature importance* bawaan seperti pada Random Forest. Berdasarkan hasil visualisasi pada gambar di atas, fitur *daily_screen_time_hours* menjadi variabel dengan pengaruh paling tinggi secara signifikan dalam proses klasifikasi. Posisi berikutnya ditempati oleh fitur *social_media_hours*, *gaming_hours*, dan *notifications_per_day*.

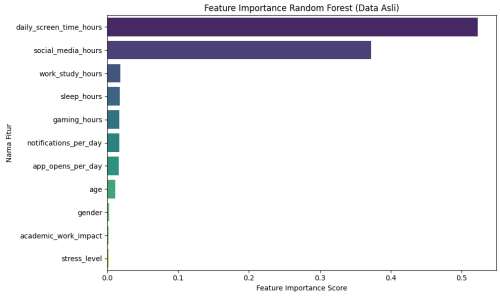
Hal ini menunjukkan bahwa durasi penggunaan smartphone, intensitas media sosial, serta frekuensi interaksi terhadap perangkat memiliki kontribusi besar dalam menentukan tingkat kecanduan pengguna. Sebaliknya, fitur seperti *academic_work_impact* dan *stress_level* memiliki nilai *importance* yang sangat rendah atau mendekati nol, sehingga pengaruhnya terhadap performa prediksi model KNN relatif kecil.

Pada algoritma Random Forest (RF), *feature importance* diperoleh berdasarkan kontribusi setiap fitur dalam membentuk pemisahan data pada pohon keputusan. Hasil visualisasi pada gambar kedua di atas menunjukkan pola yang relatif serupa dengan model KNN, di mana fitur *daily_screen_time_hours* kembali mendominasi sebagai fitur paling penting, diikuti oleh *social_media_hours*. Selanjutnya, fitur seperti *notifications_per_day*, *work_study_hours*, *app_opens_per_day*, *sleep_hours*, dan *gaming_hours* memiliki tingkat kepentingan yang hampir setara. Fitur-fitur tersebut berkontribusi dalam membantu model membedakan karakteristik pengguna pada setiap kategori *addiction level*. Sementara itu, fitur seperti *academic_work_impact*, *gender*, dan *stress_level* berada pada urutan terbawah dengan skor kepentingan paling rendah.

Berdasarkan hasil analisis dari kedua model tersebut, dapat disimpulkan bahwa faktor utama yang paling konsisten memengaruhi tingkat kecanduan smartphone adalah durasi penggunaan layar harian (*daily_screen_time_hours*) dan intensitas penggunaan media sosial (*social_media_hours*). Selain itu, fitur yang berkaitan dengan frekuensi interaksi pengguna terhadap smartphone, seperti jumlah

notifikasi dan intensitas bermain game, juga memiliki kontribusi yang cukup signifikan. Temuan ini menunjukkan bahwa kuantitas waktu yang dihabiskan di depan layar, khususnya untuk aktivitas media sosial, merupakan indikator terkuat dalam menentukan tingkat kecanduan smartphone seseorang. Oleh karena itu, hasil penelitian ini dapat dimanfaatkan sebagai dasar dalam upaya edukasi kesehatan digital dan pengendalian penggunaan smartphone agar lebih seimbang dan terkontrol, khususnya di lingkungan mahasiswa.





Feature Importance Pada Setiap Model Data Asli

Analisis *feature importance* pada skenario data asli (*imbalanced*) dilakukan untuk mengetahui bagaimana model mengambil keputusan sebelum dilakukan penanganan ketidakseimbangan kelas menggunakan metode SMOTE. Hasil visualisasi menunjukkan pola distribusi kepentingan fitur yang sangat tidak merata, sekaligus menjelaskan mengapa performa model pada data asli cenderung bias terhadap kelas mayoritas.

Pada model Random Forest (RF) data asli, terlihat bahwa fitur *daily_screen_time_hours* memiliki skor kepentingan paling dominan dengan nilai diatas 0.50, kemudian diikuti oleh fitur *social_media_hours* dengan skor sekitar 0.37. Dominasi kedua fitur tersebut menunjukkan bahwa hampir seluruh proses pengambilan keputusan model hanya bergantung pada durasi penggunaan layar harian dan intensitas penggunaan media sosial. Jika digabungkan, kedua fitur ini mencakup hampir 90% kontribusi terhadap proses klasifikasi model. Sementara itu, fitur-fitur lain seperti *work_study_hours*, *sleep_hours*, *notifications_per_day*, hingga *stress_level* memiliki skor kepentingan yang sangat kecil atau mendekati nol. Kondisi ini menunjukkan bahwa struktur pohon keputusan pada Random Forest gagal mempelajari pola yang lebih kompleks akibat distribusi kelas yang tidak seimbang. Model cenderung mengambil jalur termudah dengan hanya mengandalkan dua fitur utama untuk memprediksi kelas mayoritas sehingga kemampuan generalisasi terhadap kelas minoritas menjadi sangat lemah.

Pada model K-Nearest Neighbors (KNN) data asli, pola yang serupa juga terlihat melalui hasil *permutation importance*. Fitur *daily_screen_time_hours* dan *social_media_hours* kembali menjadi dua fitur dengan pengaruh tertinggi terhadap performa model. Pengacakan pada fitur *daily_screen_time_hours* menyebabkan penurunan akurasi paling besar, disusul oleh fitur *social_media_hours*. Hal ini menunjukkan bahwa kedua fitur tersebut menjadi penentu utama dalam

proses pencarian tetangga terdekat pada algoritma KNN.

Namun, terdapat fenomena menarik pada hasil *permutation importance* KNN, yaitu munculnya beberapa fitur dengan nilai *Mean Importance Drop* negatif. Fitur-fitur seperti *sleep_hours*, *academic_work_impact*, dan beberapa variabel lainnya justru menunjukkan peningkatan atau tidak adanya perubahan akurasi ketika fitur tersebut diacak. Dalam konteks evaluasi KNN, nilai negatif ini mengindikasikan bahwa fitur-fitur tersebut tidak membantu model dalam menentukan tetangga terdekat yang relevan, melainkan bertindak sebagai *noise* yang mengganggu perhitungan jarak antar data. Akibatnya, keberadaan fitur-fitur tersebut justru menurunkan kualitas klasifikasi pada kondisi data yang tidak seimbang.

Berdasarkan hasil analisis kedua model, dapat disimpulkan bahwa pada skenario data asli (*imbalanced*), model cenderung hanya berfokus pada fitur-fitur dominan seperti *daily_screen_time_hours* dan *social_media_hours* untuk memprediksi tingkat kecanduan smartphone. Ketidakseimbangan distribusi kelas menyebabkan sebagian besar fitur lain gagal dimanfaatkan secara optimal oleh model. Temuan ini sekaligus memperkuat alasan pentingnya penerapan metode penyeimbangan data seperti SMOTE agar model mampu mempelajari pola dari seluruh kelas secara lebih adil dan objektif.

4. KESIMPULAN DAN SARAN

Berdasarkan hasil penelitian dan analisis yang telah dilakukan, dapat disimpulkan bahwa algoritma K-Nearest Neighbors (KNN) dan Random Forest berhasil diimplementasikan untuk melakukan klasifikasi tingkat kecanduan smartphone berdasarkan pola perilaku penggunaan digital pengguna. Dataset Smartphone Usage and Addiction Analysis mampu memberikan representasi yang cukup baik dalam memodelkan hubungan antara aktivitas penggunaan smartphone dengan tingkat kecanduan pengguna.

Hasil eksperimen menunjukkan bahwa kondisi ketidakseimbangan kelas (class imbalance) sangat memengaruhi performa model klasifikasi. Pada data asli (imbalanced), model cenderung bias terhadap kelas mayoritas sehingga kemampuan dalam mengenali kelas minoritas menjadi rendah. Penerapan metode Synthetic Minority Over-sampling Technique (SMOTE) terbukti mampu meningkatkan keseimbangan distribusi data dan membantu model dalam mengenali seluruh kelas secara lebih adil.

Pada algoritma KNN, penggunaan data asli menghasilkan akurasi sebesar 46%, sedangkan penggunaan data hasil SMOTE menghasilkan akurasi sebesar 44%. Meskipun akurasi sedikit menurun setelah dilakukan SMOTE, performa klasifikasi menjadi lebih objektif karena nilai recall pada kelas minoritas meningkat secara signifikan. Sementara itu, pada algoritma Random Forest, eksperimen menggunakan data asli memperoleh akurasi sebesar 51.27%, sedangkan pada data SMOTE diperoleh akurasi sebesar 49.67%. Walaupun akurasi pada data asli lebih tinggi, model Random Forest dengan SMOTE menunjukkan distribusi prediksi yang lebih stabil, seimbang, dan tidak terlalu bias terhadap

kelas tertentu.

Berdasarkan perbandingan keseluruhan performa model, Random Forest dengan SMOTE menjadi model yang paling baik dan paling sehat secara klasifikasi karena mampu menghasilkan prediksi yang lebih merata pada seluruh kategori addiction level. Selain itu, analisis feature importance menunjukkan bahwa fitur daily_screen_time_hours dan social_media_hours merupakan faktor yang paling dominan dalam menentukan tingkat kecanduan smartphone. Fitur lain seperti notifications_per_day dan gaming_hours juga memberikan kontribusi yang cukup signifikan terhadap proses prediksi model.

Dengan demikian, penelitian ini membuktikan bahwa pendekatan machine learning dapat digunakan sebagai solusi objektif dalam mendeteksi tingkat kecanduan smartphone, sekaligus memberikan wawasan mengenai faktor-faktor perilaku digital yang paling berpengaruh terhadap kecanduan smartphone di lingkungan mahasiswa.

SARAN:

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat diberikan untuk pengembangan penelitian selanjutnya, yaitu sebagai berikut:

1. Penelitian selanjutnya disarankan untuk menggunakan dataset dengan jumlah data yang lebih besar dan distribusi kelas yang lebih seimbang agar performa model dapat meningkat dan menghasilkan generalisasi yang lebih baik.
2. Penelitian berikutnya dapat mencoba algoritma machine learning lain yang lebih kompleks, seperti XGBoost, LightGBM, Support Vector Machine (SVM), atau Neural Network untuk memperoleh performa klasifikasi yang lebih optimal
3. Proses feature engineering dan feature selection dapat dikembangkan lebih lanjut agar model mampu mempelajari pola perilaku pengguna secara lebih mendalam dan mengurangi pengaruh noise pada data.
4. Penelitian selanjutnya juga dapat menambahkan variabel lain yang berkaitan dengan kondisi psikologis, kebiasaan belajar, maupun kesehatan mental pengguna agar hasil prediksi tingkat kecanduan smartphone menjadi lebih komprehensif.

Hasil penelitian ini diharapkan dapat menjadi dasar pengembangan sistem monitoring atau aplikasi deteksi dini kecanduan smartphone yang dapat digunakan sebagai media edukasi kesehatan digital, khususnya di lingkungan mahasiswa dan generasi muda.

5. DAFTAR PUSTAKA

[1] Chen, Y., dkk. (2026). Smartphone Addiction, Use Preferences, and Depression Among Older Adults in the Digital Context: Machine Learning Analysis of Survey Data. *JMIR Aging*, 9, e84703.

[2] Vimala, S., & Sahaya Sheela, G. A. (2026). Predictive Modeling of the Impact of Smartphone Addiction on Students' Academic Performance Using Machine Learning. *International Journal of IT, Research and Applications*, 4(3), 8-15.

[3] Zhu, J., dkk. (2025). Predicting Digital Addiction Patterns with Machine Learning for Personalised Mental Health Support. *Journal of Social Computing*, 6(4), 359-377.

[4] Wibisono, A. D. R., dkk. (2025). Predicting Smartphone Addiction Levels with K-Nearest Neighbors Using User Behavior Patterns. *Jurnal Teknik Informatika (Jutif)*, 6(5).

[5] Sebastian, V. (2025). *Klasifikasi Tingkat Kecanduan Pengguna Smartphone Menggunakan Machine Learning dengan Optimasi Feature Weighting* (Skripsi). Universitas AMIKOM Yogyakarta